

# PRD — Voice Assistant Mobile App

Versi: 1.0 · Tanggal: 12 Juli 2026 · Status: Draft · Tipe: Proyek pribadi / pembelajaran

---

## 1. Ringkasan

Voice assistant berbasis mobile app dengan dua mode interaksi: **chat teks interaktif** bergaya Telegram (mendukung command seperti `/help`) dan **percakapan suara real-time full duplex** yang terasa natural seperti berbicara dengan manusia, termasuk kemampuan saling memotong pembicaraan (barge-in). Suara asisten dapat dikustomisasi menggunakan sampel suara yang tersedia di folder `voice/`.

UI chat sudah tersedia. Fokus pekerjaan proyek ini adalah **membangun backend (Python), mendesain API, dan integrasi FE-BE**.

## 2. Latar Belakang & Masalah

Chat UI sudah jadi tetapi belum berfungsi karena belum ada backend. Belum ada API contract antara FE dan BE, belum ada integrasi LLM, dan belum ada pipeline suara (STT/TTS). Proyek ini sekaligus menjadi sarana belajar arsitektur aplikasi AI end-to-end: streaming, WebSocket, LLM orchestration, dan voice pipeline.

## 3. Tujuan (Goals)

1. Chat teks berfungsi penuh dengan respons streaming dan indikator "sedang mengetik / berpikir".
2. Sistem command ala Telegram (`/help`, `/clear`, dll.) berjalan di sisi backend.
3. Percakapan suara real-time full duplex dengan latensi respons < 1,5 detik dan dukungan interupsi (barge-in).
4. Suara asisten bisa diganti dengan suara hasil cloning dari file audio di folder `voice/`.
5. Backend Python yang modular: mudah gonta-ganti model LLM (Gemini sebagai default, dengan fallback ke provider gratis lain).
6. Biaya operasional Rp0 — semua layanan memakai free tier atau open source yang dijalankan sendiri.

### Non-Goals (di luar scope v1)

Autentikasi multi-user, monetisasi, dukungan panggilan telepon nyata (PSTN), deployment production skala besar, dan wake word ("Hey Assistant...") tidak termasuk dalam versi ini.

## 4. Pengguna & Use Case

Pengguna utamanya adalah developer sendiri (single user). Use case utama: bertanya dan mengobrol lewat teks seperti chatting biasa, mengobrol lewat suara secara hands-free (misal sambil beraktivitas), dan bereksperimen dengan berbagai model AI serta suara custom.

## 5. Fitur & Requirements

### 5.1 Chat Interaktif (Mode Teks)

| ID   | Requirement                                                                                              | Prioritas |
|------|----------------------------------------------------------------------------------------------------------|-----------|
| CH-1 | Kirim/terima pesan teks dengan respons streaming (token per token, seperti ChatGPT)                      | P0        |
| CH-2 | Indikator status: "typing..." saat streaming, ikon "berpikir 🤔" saat menunggu respons pertama dari model | P0        |
| CH-3 | Sistem command dengan prefix / (lihat tabel command di bawah)                                            | P0        |
| CH-4 | Riwayat percakapan tersimpan (context memory per sesi)                                                   | P0        |
| CH-5 | Render markdown pada balasan (bold, code block, list)                                                    | P1        |
| CH-6 | Auto-suggest command saat user mengetik / (seperti Telegram)                                             | P2        |

**Daftar command v1:**

| Command | Fungsi                                                             |
|---------|--------------------------------------------------------------------|
| /help   | Menampilkan daftar semua command                                   |
| /start  | Mulai sesi baru + pesan sambutan                                   |
| /clear  | Hapus riwayat/context percakapan                                   |
| /model  | Lihat & ganti model LLM aktif (contoh: /model gemini, /model groq) |
| /voice  | Lihat & ganti suara asisten (contoh: /voice budi)                  |
| /status | Info sesi: model aktif, suara aktif, jumlah token terpakai         |

## 5.2 Voice Conversation (Mode Suara)

| ID   | Requirement                                                                                                              | Prioritas |
|------|--------------------------------------------------------------------------------------------------------------------------|-----------|
| VC-1 | Percakapan suara dua arah lewat WebSocket (audio streaming)                                                              | P0        |
| VC-2 | <b>Full duplex + barge-in:</b> user bisa memotong saat asisten sedang bicara, asisten langsung berhenti dan mendengarkan | P0        |
| VC-3 | Voice Activity Detection (VAD) untuk mendeteksi kapan user mulai/selesai bicara tanpa tombol push-to-talk                | P0        |
| VC-4 | Transkrip percakapan suara tampil di layar secara real-time                                                              | P1        |
| VC-5 | Latensi ucapan-ke-respons < 1,5 detik (target), < 3 detik (batas maksimal)                                               | P1        |

| ID   | Requirement                                                                                                                          | Prioritas |
|------|--------------------------------------------------------------------------------------------------------------------------------------|-----------|
| VC-6 | Suara custom: TTS memakai suara hasil cloning dari file di folder <b>voice/</b> (format .wav/.mp3, minimal 6–10 detik sampel bersih) | P1        |

 **Catatan etika voice cloning:** hanya gunakan sampel suara milik sendiri atau orang yang sudah memberi izin eksplisit. Jangan meng-clone suara figur publik atau orang lain tanpa persetujuan.

### 5.3 Backend & API

| ID   | Requirement                                                                       | Prioritas |
|------|-----------------------------------------------------------------------------------|-----------|
| BE-1 | Backend Python dengan <b>FastAPI</b> (async, WebSocket native, auto-docs Swagger) | P0        |
| BE-2 | Abstraksi LLM provider — ganti model cukup lewat config/command, tanpa ubah kode  | P0        |
| BE-3 | REST API untuk chat + WebSocket untuk streaming teks & audio                      | P0        |
| BE-4 | Rate-limit handling & fallback otomatis antar provider saat kuota free tier habis | P1        |
| BE-5 | Logging & error handling yang rapi untuk debugging                                | P1        |

## 6. Rekomendasi Teknologi & Model

### 6.1 LLM (otak asisten)

Soal pertanyaan "GPT free" — **OpenAI tidak menyediakan API gratis**, jadi GPT via API akan berbayar. Alternatif gratis yang bagus:

| Provider                             | Model                            | Free tier       | Catatan                                                       |
|--------------------------------------|----------------------------------|-----------------|---------------------------------------------------------------|
| <b>Google AI Studio</b> ★<br>default | Gemini 2.5 Flash /<br>Flash-Lite | Ya, cukup besar | Pilihan utama. Cepat,<br>pintar, multimodal                   |
| <b>Groq</b> ★ fallback               | Llama 3.3 70B, dll.              | Ya              | Inference tercepat di<br>kelasnya — ideal<br>untuk mode suara |
| <b>OpenRouter</b>                    | Berbagai model<br>ber-tag :free  | Ya (terbatas)   | Satu API untuk<br>banyak model, cocok<br>buat eksperimen      |
| Ollama (lokal)                       | Llama/Qwen kecil                 | Gratis penuh    | Opsional; butuh<br>PC/server sendiri,<br>offline              |

Gunakan library **LiteLLM** di backend agar semua provider di atas bisa dipanggil lewat satu interface seragam — ini yang membuat `/model` untuk gonta-ganti model jadi gampang.

## 6.2 Voice Pipeline — dua jalur (trade-off penting)

Ada ketegangan antara dua keinginan: *full duplex semudah mungkin* vs *suara custom hasil cloning*. Solusinya, sediakan **dua mode**:


**Mode A — Gemini Live API (rekomendasi untuk full duplex):** Gemini punya **Live API** (Multimodal Live) yang mendukung percakapan audio native, real-time, full duplex, dengan interupsi/barge-in yang sudah ditangani otomatis, dan tersedia di free tier AI Studio. Ini jalur tercepat untuk mendapat pengalaman "ngobrol kayak manusia". **Kekurangannya:** suara terbatas pada preset voice bawaan Google — tidak bisa pakai suara custom dari folder `voice/`.

**Mode B — Pipeline custom (untuk suara cloning):** Rangkaian STT → LLM → TTS yang dirakit sendiri:

- **STT:** `faster-whisper` (lokal, gratis) atau **Groq Whisper API** (free tier, sangat cepat)
- **VAD:** **Silero VAD** (open source, ringan) untuk deteksi bicara + barge-in
- **LLM:** Gemini Flash / Groq (via LiteLLM)
- **TTS + cloning:** **Coqui XTTS v2** atau **F5-TTS** (open source) — bisa clone suara dari sampel 6–10 detik, mendukung streaming output. Dijalankan di backend (butuh GPU agar cepat; tanpa GPU tetap jalan tapi lebih lambat)

Mode B secara teknis "semi-duplex dengan barge-in" (interupsi ditangani manual lewat VAD: saat user bicara, playback dihentikan dan pipeline di-reset). Hasilnya tetap terasa natural meski implementasinya lebih kompleks daripada Mode A.

### 6.3 Arsitektur



## 7. Desain API (Draft)

### REST

| Method | Endpoint                               | Fungsi                                     |
|--------|----------------------------------------|--------------------------------------------|
| POST   | <code>/api/chat</code>                 | Kirim pesan (non-streaming, fallback)      |
| GET    | <code>/api/session/{id}/history</code> | Ambil riwayat chat                         |
| DELETE | <code>/api/session/{id}</code>         | Hapus sesi (dipakai <code>/clear</code> )  |
| GET    | <code>/api/models</code>               | Daftar model tersedia                      |
| PUT    | <code>/api/session/{id}/model</code>   | Ganti model aktif                          |
| GET    | <code>/api/voices</code>               | Daftar suara di folder <code>voice/</code> |
| PUT    | <code>/api/session/{id}/voice</code>   | Ganti suara aktif                          |

### WebSocket

| Endpoint                               | Fungsi                                                                                                                           |
|----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| WS <code>/ws/chat/{session_id}</code>  | Streaming teks: event <code>thinking</code> → <code>typing</code> (token stream) → <code>done</code>                             |
| WS <code>/ws/voice/{session_id}</code> | Streaming audio dua arah: chunk audio user masuk, chunk audio TTS keluar, event <code>interrupt</code> , <code>transcript</code> |

Command (`/help` dll.) dikirim sebagai pesan biasa; backend mendeteksi prefix `/` lewat Command Router dan merespons tanpa memanggil LLM.

## 8. Roadmap / Milestone

| Fase                                          | Deliverable                                                                                                                                                                                                                | Estimasi   |
|-----------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| <b>Fase 1 — Chat Core</b>                     | FastAPI up, integrasi Gemini via LiteLLM, REST + WS chat streaming, event thinking/typing, command router ( <code>/help</code> , <code>/start</code> , <code>/clear</code> , <code>/status</code> ), riwayat sesi (SQLite) | 1–2 minggu |
| <b>Fase 2 — Multi-model</b>                   | <code>/model</code> , fallback antar provider, rate-limit handling                                                                                                                                                         | 3–5 hari   |
| <b>Fase 3 — Voice Mode A</b>                  | Integrasi Gemini Live API: ngobrol full duplex dengan preset voice + transkrip real-time                                                                                                                                   | 1–2 minggu |
| <b>Fase 4 — Voice Mode B</b>                  | Pipeline VAD + faster-whisper + XTTS/F5-TTS, voice cloning dari folder <code>voice/</code> , <code>/voice</code> command, barge-in manual                                                                                  | 2–3 minggu |
| <b>Fase 5 — Polish</b>                        | Optimasi latensi, error handling, UX kecil (auto-suggest command, markdown render), background audio iOS                                                                                                                   | 1 minggu   |
| <b>Fase 6 — Bahasa Daerah (eksperimental)</b> | System prompt multibahasa, Whisper language hint, TTS fallback router (MMS-TTS untuk Jawa/Sunda)                                                                                                                           | 1 minggu   |

## 9. Metrik Keberhasilan

1. Chat streaming berjalan mulus dengan first-token < 2 detik.
2. Semua command v1 berfungsi.
3. Mode suara A: percakapan berkelanjutan ≥ 5 menit tanpa putus, interupsi bekerja.

4. Mode suara B: suara hasil cloning terdengar mirip sampel, latensi ucapan-ke-respons < 3 detik.
5. Fallback model otomatis bekerja saat kuota Gemini habis.

## 10. Risiko & Mitigasi

| Risiko                                                               | Dampak                                | Mitigasi                                                                                         |
|----------------------------------------------------------------------|---------------------------------------|--------------------------------------------------------------------------------------------------|
| Kuota free tier habis (Gemini/Groq)                                  | Asisten mati                          | Fallback otomatis antar provider (BE-4); tampilkan status kuota di <code>/status</code>          |
| Latensi Mode B tinggi tanpa GPU                                      | Percakapan terasa lambat              | Pakai model TTS kecil, streaming per kalimat; atau tetap di Mode A untuk daily use               |
| Gemini Live API masih berubah-ubah (preview)                         | Breaking changes                      | Isolasi di satu modul <code>voice_mode_a.py</code> agar mudah diperbaiki                         |
| Kualitas cloning kurang mirip                                        | Suara tidak memuaskan                 | Sampel audio bersih tanpa noise, 10–30 detik, coba XTTS v2 vs F5-TTS lalu pilih terbaik          |
| Barge-in Mode B false-positive (kepotong suara sendiri dari speaker) | UX buruk                              | AEC bawaan iOS ( <code>AVAudioSession.voiceChat</code> ) + threshold VAD                         |
| Kualitas STT/TTS bahasa daerah rendah                                | Salah transkrip, suara kurang natural | Statuskan sebagai fitur eksperimental (Fase 6); fallback ke Bahasa Indonesia bila deteksi gagal  |
| Laptop mati/sleep saat dipakai dari luar                             | Asisten tidak bisa diakses            | Atur power settings; pertimbangkan pindah ke VPS/Railway di masa depan bila mulai sering dipakai |

## 11. Keputusan Platform & Deployment (Resolved)

### 11.1 Platform: iOS native (dulu)

Fokus pertama iOS. Implikasi teknis di sisi FE:

| Kebutuhan                                    | Teknologi iOS                                                                                 |
|----------------------------------------------|-----------------------------------------------------------------------------------------------|
| Audio capture & playback streaming           | <b>AVAudioEngine</b> (tap mic → kirim chunk PCM 16kHz via WS; playback buffer dari chunk TTS) |
| Echo cancellation (penting untuk barge-in)   | <b>AVAudioSession</b> mode <b>.voiceChat</b> — AEC bawaan iOS aktif otomatis                  |
| WebSocket client                             | <b>URLSessionWebSocketTask</b> (bawaan) atau <b>Starscream</b>                                |
| Izin mikrofon                                | <b>NSMicrophoneUsageDescription</b> di Info.plist                                             |
| Background audio (ngobrol sambil layar mati) | Background mode <b>audio</b> — masuk Fase Polish                                              |

Catatan: build iOS butuh Mac + Xcode; testing di device fisik bisa dengan free Apple Developer account (app expire tiap 7 hari — cukup untuk proyek belajar).

### 11.2 Backend: laptop sendiri

Backend jalan di laptop → iPhone harus bisa menjangkau laptop. Opsi dari yang paling simpel:

1. **Satu WiFi yang sama** — akses langsung ke **http://<ip-laptop>:8000**. Paling gampang untuk development.
2. **Tailscale** (gratis) — laptop & iPhone dalam satu VPN pribadi, tetap konek walau beda jaringan. Rekomendasi utama begitu mulai sering testing di luar rumah.
3. **ngrok / cloudflared tunnel** (gratis) — expose sementara ke internet, cocok untuk demo.

Konsekuensi lain: XTTS/F5-TTS ikut jalan di laptop. Kalau laptopnya Mac Apple Silicon, TTS open source tetap bisa jalan (PyTorch MPS) tapi lebih lambat dari GPU NVIDIA — streaming TTS per kalimat (bukan tunggu semua selesai) jadi wajib agar latensi terasa oke.

### 11.3 Bahasa: campur Indonesia–Inggris + bahasa daerah

Ini bagian yang paling menantang karena dukungan tiap komponen berbeda:

| Komponen                 | Indonesia  | Inggris    | Bahasa daerah<br>(Jawa, Sunda, dll.)                                |
|--------------------------|------------|------------|---------------------------------------------------------------------|
| LLM (Gemini/Llama)       | ✓ Bagus    | ✓ Bagus    | ⚠ Cukup baik untuk Jawa & Sunda; makin kecil bahasanya makin lemah  |
| STT Whisper              | ✓ Bagus    | ✓ Bagus    | ⚠ Ada dukungan Jawa (jw) & Sunda (su), akurasi lebih rendah         |
| TTS XTTS v2<br>(cloning) | ✓ Didukung | ✓ Didukung | ✗ Tidak didukung                                                    |
| TTS Meta <b>MMS-TTS</b>  | ✓          | ✓          | ✓ Jawa & Sunda didukung (tapi <b>tanpa</b> cloning — suara generik) |
| Gemini Live (Mode A)     | ✓          | ✓          | ⚠ Mengerti teksnya, tapi output suara tidak dijamin natural         |

**Strategi yang ditetapkan:** percakapan campur ID–EN jadi first-class citizen — semua komponen mendukung code-switching dengan baik, dan XTTS v2 bisa cloning untuk kedua bahasa itu. Bahasa daerah berstatus **best-effort/eksperimental**: LLM diberi system prompt agar merespons dalam bahasa daerah bila diajak, STT pakai Whisper dengan language hint, dan TTS memakai **fallback router** — jika teks terdeteksi bahasa daerah, pakai MMS-TTS (suara generik); jika ID/EN, pakai XTTS suara custom. Fitur ini masuk sebagai **Fase 6 (eksperimental)** setelah semua fitur inti stabil.